

Data Mining HW3

1. Describe how you solve this problem. Details include preprocessing, embeddings, model selection, hyperparameters should be provided.

- **Baseline :**

讀取提供的實體向量 `train/test_entity_embedding.vec` (約 100 維), 新聞向量 = 實體均值, 用戶向量 = 歷史新聞均值, 分數 = 點積, 無訓練, 直接生成提交。

- **GRU:**

- **歷史序列處理:** 將用戶 clicked_news 轉為新聞向量序列, 截斷最近 max_history_len(預設 50), 用零向量右填充到固定長度, 便於 Mask。
- **模型:** 歷史序列 (max_history_len, dim) + 候選新聞向量 (dim)。歷史序列經 Masking(0) -> GRU(hidden=128 默認) 得到用戶向量。候選經 Dense(hidden, ReLU) 投影後與用戶向量相加, 再 ReLU, 最後 Dense(1) + Sigmoid 輸出點擊概率。
- **訓練:** 對每條行為的每個帶標籤候選生成 (歷史序列, 候選向量, 標籤) 樣本; shuffle 後 batch (預設 128), 使用 BCE 損失, Adam(1e-3 默認), 訓練 epochs=2 默認。

- **TF-IDF + Sentence-BERT + MLP:**

- **文本稀疏特徵:** HashingVectorizer (n_features=2**18, 英語停用詞, lowercase=True, norm='l2', 'alternate_sign=False) 生成 TF-IDF; 用戶向量取歷史平均。
- **句向量:** SentenceTransformer("all-MiniLM-L12-v2"), batch=512 (encode batch=64), 歸一化; 用戶句向量為歷史平均, 無歷史回退零向量。
- **特徵:** 每個 user-candidate 組合構造 [tfidf_cos, dense_cos, user_dense, cand_dense, user_dense * cand_dense], 其中前兩項為餘弦相似度, 最後一項為逐元素乘積交互。
- **模型:** 兩層 MLP (256-ReLU + Dropout0.2, 128-ReLU, Sigmoid 輸出), BCE 損失, Adam(1e-3)。訓練使用前 30k 行行為 (max_train_rows=30000), batch_size=2048, epochs=4, 驗證 5%。
- **推理:** 按同樣特徵生成概率, 不足 15 候選補零, 輸出分數。

2. Choose a **variable (e.g. different model, different approach)** **excluding hyperparameters** and compare their performance. Explain what causes the difference of performance or why.

Method	Score
Baseline	0.5436
GRU	0.6140
TF-IDF + Sentence-BERT + MLP	0.6963

Baseline 只用實體均值點積，實體覆蓋有限且缺詞級語義，很多新聞退化成近零向量，導致相關性弱，得分最低。

GRU 仍只吃實體均值，雖然加了序列建模能利用最近歷史，但輸入信息不足，提升有限。

TF-IDF + Sentence-BERT + MLP 同時用詞級匹配（TF-IDF 餘弦）和句級語義（SBERT），再用逐元素乘積顯式建 user-candidate 交互，信息量和交互力最強；對無實體、短標題或噪聲實體的樣本也更穩健，因此得分最高

3. Do some error analysis or case study. Is there anything worth mentioning while checking the mispredicted data? Share with us.

- 相似候選的相對順序：同一 impression 內多條高度相似的新聞，模型給出接近分數，微小噪聲導致排序錯位；可加入去重或候選重排策略緩解。
- 時間漂移：歷史多為舊內容時，對新事件打分偏低，錯殺近期熱門；時間權重或近期窗口能減少此類誤差。